

RAPPORT : Analyse de l'impact des réseaux sociaux sur la santé mentale

1. Introduction

Ce projet analyse l'impact du temps d'écran et des usages des réseaux sociaux sur la santé mentale. À partir d'un dataset issu de Kaggle, l'objectif est d'étudier les relations entre comportements numériques, stress, sommeil et bien-être, et d'identifier des profils d'utilisateurs à l'aide de méthodes statistiques et de clustering.

2. Nettoyage & Exploration

Étapes de nettoyage :

Le jeu de données initial (Mental_Health_and_Social_Media_Balance_Dataset.csv) contenait 500 individus. L'analyse initiale a révélé que le dataset était déjà relativement propre, sans valeurs manquantes significatives et sans doublons. L'étape de nettoyage appliquée a consisté à exclure la catégorie « Other » de la variable Gender.

Variables retenues :

Six variables numériques ont été conservées pour l'analyse :

1. Daily_Screen_Time(hrs) – Temps d'écran quotidien
2. Sleep_Quality(1-10) – Qualité du sommeil
3. Stress_Level(1-10) – Niveau de stress perçu
4. Days_Without_Social_Media – Jours sans réseaux sociaux
5. Exercise_Frequency(week) – Fréquence d'exercice hebdomadaire
6. Happiness_Index(1-10) – Indice de bonheur
7. Age – Âge de l'individu

Visualisations :

Des graphiques exploratoires (histogrammes, boxplots, nuages de points) ont été générés. Ils révèlent notamment :

- Une tendance à l'augmentation du stress avec le temps d'écran
- Une corrélation négative entre temps d'écran et qualité du sommeil
- Des distributions variables selon les plateformes de médias sociaux

Observations principales :

L'exploration confirme que les individus avec un temps d'écran élevé (>7h/jour) présentent généralement des scores de stress plus élevés et une qualité de sommeil plus faible. À l'inverse, ceux pratiquant une activité physique régulière et prenant des pauses numériques montrent de meilleurs indicateurs de bien-être.

3. Analyse Statistique & ACP

Le dataset initial contient 500 individus. Afin d'améliorer la lisibilité et l'interprétation des résultats de l'Analyse en Composantes Principales (ACP) et du clustering, un sous-ensemble de 100 individus a été sélectionné

3.1. Première ACP (Analyse Complète)

Une première Analyse en Composantes Principales (ACP) a été réalisée sur un dataset de 477 individus. Le graphe d'éboulis montre que la première composante (Dim 1) explique 44,5% de la variance totale, tandis que les deux premières composantes cumulent 59,8% de la variance. Ces composantes ont été retenues pour leur pouvoir explicatif.

Interprétation des axes :

- **Dim 1** représente principalement le contraste entre **exposition numérique/stress** (temps d'écran élevé, stress élevé) et **bien-être** (qualité du sommeil, bonheur).
- **Dim 2** met en évidence le rôle de **l'âge et de l'activité physique**, avec une corrélation positive entre ces deux variables.

3.2. Seconde ACP (Analyse Ciblée)

Une seconde ACP a été réalisée sur sous-ensemble avec un focus sur 4 variables clés : âge, temps d'écran, niveau de stress et fréquence d'exercice. Cette analyse explique 72,8% de la variance avec deux dimensions.

Matrice des composantes :

- **Dim 1** (43,0% variance) : fortement corrélée avec le temps d'écran (0,69) et le stress (0,70)
- **Dim 2** (29,8% variance) : corrélée avec l'âge (0,71) et l'exercice (0,68)

3.3. Contribution des Individus

L'analyse des contributions montre que plusieurs individus sont particulièrement bien représentés sur Dim 2 ($\text{COS}^2 > 0,70$). Ces individus présentent des profils extrêmes en termes d'âge et d'activité physique.

Cartes des individus : Les représentations graphiques montrent une dispersion continue des individus dans l'espace factoriel, avec :

- Un gradient dominant le long de Dim 1 opposant les profils à fort usage numérique/stress aux profils équilibrés
- Une différenciation secondaire le long de Dim 2 basée sur l'âge et l'activité physique

4. Clustering (HC & KMeans)

4.1. Méthodologie

Un clustering hiérarchique utilisant la méthode de Ward a été appliqué, suivi d'une consolidation par K-Means avec $k = 2$. Ce choix a été validé par la méthode du coude et l'interprétabilité des résultats.

4.2. Interprétation des Clusters

Trois profils distincts ont été identifiés :

1. **Cluster 0 – Profil Tendu et Hyper-Connecté :** Stress élevé, temps d'écran important, activité physique faible.
2. **Cluster 1 – Profil Équilibré et Serein :** Stress modéré, temps d'écran réduit, activité physique plus élevée.

Conclusion

Cette étude confirme la corrélation entre usage intensif des écrans et détérioration du bien-être mental (stress accru, sommeil dégradé). L'ACP révèle deux axes principaux : exposition numérique/stress vs bien-être, et rôle de l'âge/activité physique. Le clustering identifie deux profils dont un à risque (hyper-connecté, stressé, peu actif).

Limites : Données auto-déclarées, échantillon réduit.

Améliorations : Étendre l'analyse, intégrer des données objectives, affiner les modèles.